Unsupervised Dense Information Retrieval with Contrastive Learning

Майя Горшенина, Соня Черноусенко

Main research question

Можно ли обучить dense retriever без разметки и приблизиться к качеству BM25 или превзойти его?

Справка: **Dense retrievers** ищут по семантической близости векторов, но обычно требуют supervised data

План исследования

1) Обучение dense retriever
2) Unsupervised recall@10k
3) BEIR benchmark
4) Cross-lingual retrieval
5) Few-shot retrival

Contriver

Contriever представляет собой dense bi-encoder

Как работает обучение?

1) Из одного текста получаются две версии, прогоняем одну через query encoder, а вторую через key encoder
2) Из key эмбеддингов получаем позитивные эмбеддинги, негативные получаем из старых keys из очереди
3) Считаем contrastive loss – для позитивных он должен быть ближе, для негативных дальше, обновляем query encoder по градиенту
4) Сдвигаем key encoder в сторону query encoder с помощью momentum update
5) Кладем использованные keys в очередь

Данные для обучения и метрики качества

Датасеты

1) **NaturalQuestions** и **TriviaQA**

Метрики

1) **Recall@100** — попал ли релевантный документ в top-100.

2) **nDCG@10** — насколько хорошо упорядочен top-10.
   Авторы отдельно пишут, что Recall@100 особенно важен для ML-систем, а nDCG@10 — для сценариев, где выдачу смотрит человек.

Результаты unsupervised моделей без файнтьюнинга на QA датасетах

Table 1: **Unsupervised recall@k** on the test sets of NaturalQuestions and TriviaQA. For Inverse Cloze Task and Masked Salient Spans we report the results of Sachan et al. (2021). The Masked Salient Spans model uses annotated named entity recognition data. For BM25 we report the results of Ma et al. (2021)

	NaturalQuestions			TriviaQA		
	R@5	R@20	R@100	R@5	R@20	R@100
Inverse Cloze Task (Sachan et al., 2021)	32.3	50.9	66.8	40.2	57.5	73.6
Masked salient spans (Sachan et al., 2021)	41.7	59.8	74.9	53.3	68.2	79.4
BM25 (Ma et al., 2021)	-	62.9	78.3	-	**76.4**	**83.2**
Contriever	**47.8**	**67.8**	**82.1**	**59.4**	74.2	**83.2**
supervised model: DPR (Karpukhin et al., 2020)	-	78.4	85.4	-	79.4	85.0
supervised model: FiD-KD (Izacard & Grave, 2020a)	73.8	84.3	89.3	77.0	83.6	87.7

Сравнивали Contriever с BM25, ретриверами, обученными с **ICT** (Inverse Cloze Task (1)) и **Masked Salient Spans** (2)

1 – Способ создать positive pair без разметки: один фрагмент документа используется как query, а оставшийся контекст - как document

2 – Подход к обучению модели, когда в тексте скрываются некоторые фрагменты, а модель должна их предсказать

Результаты unsupervised моделей без файнтьюнинга на BEIR

Table 2: **BEIR Benchmark.** We report nDCG@10 on the test sets from the BEIR benchmark for bi-encoder methods without re-ranker. We also report the average and number of datasets where a method is the best ("Best on") over the entire BEIR benchmark (excluding three datasets because of their licence). Bold is the best overall. MS MARCO is excluded from the average. "CE" refers to cross-encoder.

	BM25	BM25+CE	DPR	ANCE	TAS-B	Gen-Q	ColBERT	Splade v2	Ours	Ours+CE
MS MARCO	22.8	41.3	17.7	38.8	40.8	40.8	40.1	43.3	40.7	**47.0**
Trec-COVID	65.6	**75.7**	33.2	65.4	48.1	61.9	67.7	71.0	59.6	70.1
NFCorpus	32.5	**35.0**	18.9	23.7	31.9	31.9	30.5	33.4	32.8	34.4
NQ	32.9	53.3	47.4	44.6	46.3	35.8	52.4	52.1	49.8	**57.7**
HotpotQA	60.3	70.7	39.1	45.6	58.4	53.4	59.3	68.4	63.8	**71.5**
FiQA	23.6	34.7	11.2	29.5	30.0	30.8	31.7	33.6	32.9	**36.7**
ArguAna	31.5	31.1	17.5	41.5	42.9	**49.3**	23.3	47.9	44.6	41.3
Touche-2020	**36.7**	27.1	13.1	24.0	16.2	18.2	20.2	36.4	23.0	29.8
CQADupStack	29.9	37.0.	15.3	29.6	31.4	34.7	35.0	-	34.5	**37.7**
Quora	78.9	82.5	24.8	85.2	83.5	83.0	85.4	83.8	**86.5**	82.4
DBPedia	31.3	40.9	26.3	28.1	38.4	32.8	39.2	43.5	41.3	**47.1**
Scidocs	15.8	16.6	7.7	12.2	14.9	14.3	14.5	15.8	16.5	**17.1**
FEVER	75.3	**81.9**	56.2	66.9	70.0	66.9	77.1	78.6	75.8	**81.9**
Climate-FEVER	21.3	25.3	14.8	19.8	22.8	17.5	18.4	23.5	23.7	**25.8**
Scifact	66.5	68.8	31.8	50.7	64.3	64.4	67.1	**69.3**	67.7	69.2
Avg. w/o CQA	44.0	49.5	26.3	41.3	43.7	43.1	45.1	50.6	47.5	51.2
Avg.	43.0	48.6	25.5	40.5	42.8	42.5	44.4	-	46.6	50.2
Best on	1	3	0	0	0	1	0	1	1	9

На BEIR превосходит другие виды ретриверов на 9 датасетах.

В целом данные показывают, что contrastive learning имеет огромный потенциал при обучении unsupervised ретриверов

Fine-tuning

Table 9: **Fine-tuning.** We report nDCG@10 after fine-tuning BERT and our model on MS MARCO.

	NFCorpus	NQ	FiQA	ArguAna	Quora	DBPedia	SciDocs	FEVER	Overall
BERT	28.2	44.6	25.9	35.0	84.0	34.4	13.0	69.8	42.0
Contriever	33.2	50.2	28.8	46.0	85.4	38.8	16.0	77.7	46.5

После fine-tuning на **MS MARCO**:

- Среди dense bi-encoders он дает лучшие результаты по nDCG@10 и **state-of-the-art по Recall@100**.

Few-shot

Table 3: **Few-shot retrieval.** Test nDCG@10 after training on a small in-domain training set. We compare BERT and our model, with and without an intermediate fine-tuning step on MS MARCO. Note that our unsupervised pre-training alone outperforms BERT with intermediate MS MARCO fine-tuning.

	Additional data	SciFact	NFCorpus	FiQA
# queries		729	2,590	5,500
BM25	-	66.5	32.5	23.6
BERT	-	75.2	29.9	26.1
Contriever	-	84.0	33.6	36.4
BERT	MS MARCO	80.9	33.2	30.9
Contriever	MS MARCO	**84.8**	**35.8**	**38.1**

В экспериментах с few-шотом Contriever показывает себя лучше прочих моделей, так как умеет быстро подстраивать веса при маленьком датасете

Multilingual retrieval

Table 4: **Multilingual retrieval on Mr. TyDi.** We report MRR@100 and Recall@100 on the test sets of Mr. TyDi. mContriever fine-tuned on MS MARCO is compared against its counterparts without contrastive pre-training using a similar fine-tuning recipe, referred to as *mBERT + MS MARCO*, as well as a model initialized with XLM-R referred to as *XLM-R + MS MARCO*. We also report the results after fine-tuning on Mr. TyDi for the model trained on MS MARCO.

	ar	bn	en	fi	id	ja	ko	ru	sw	te	th	avg
							MRR@100					
BM25 (Zhang et al., 2021)	36.7	41.3	15.1	28.8	38.2	21.7	28.1	32.9	39.6	42.4	41.7	33.3
mDPR (Zhang et al., 2021)	26.0	25.8	16.2	11.3	14.6	18.1	21.9	18.5	7.3	10.6	13.5	16.7
Hybrid (Zhang et al., 2021)	49.1	53.5	28.4	36.5	45.5	35.5	36.2	42.7	40.5	42.0	49.2	41.7
mBERT + MS MARCO	34.8	35.1	25.7	29.6	36.3	27.1	28.1	30.0	37.4	39.6	20.3	31.3
XLM-R + MS MARCO	36.5	41.7	23.0	32.7	39.2	24.8	32.2	29.3	35.1	54.7	38.5	35.2
mContriever	27.3	36.3	9.2	21.1	23.5	19.5	22.3	17.5	38.3	22.5	37.2	25.0
+ MS MARCO	43.4	42.3	27.1	35.1	42.6	32.4	34.2	36.1	51.2	37.4	40.2	38.4
+ Mr. Tydi	**72.4**	**67.2**	**56.6**	**60.2**	**63.0**	**54.9**	**55.3**	**59.7**	**70.7**	**90.3**	**67.3**	**65.2**
							Recall@100					
BM25 (Zhang et al., 2021)	80.0	87.4	55.1	72.5	84.6	65.6	79.7	66.0	76.4	81.3	85.3	74.3
mDPR (Zhang et al., 2021)	62.0	67.1	47.5	37.5	46.6	53.5	49.0	49.8	26.4	35.2	45.5	47.3
Hybrid (Zhang et al., 2021)	86.3	93.7	69.6	78.8	88.7	77.8	70.6	76.0	78.6	82.7	87.5	80.9
mBERT + MS MARCO	81.1	88.7	77.8	74.2	81.0	76.1	66.7	77.6	74.1	89.5	57.8	76.8
XLM-R + MS MARCO	79.9	84.2	73.1	81.6	87.4	70.9	71.1	74.1	73.9	91.2	89.5	79.7
mContriever	82.0	89.6	48.8	79.6	81.4	72.8	66.2	68.5	88.7	80.8	90.3	77.2
+ MS MARCO	88.7	91.4	77.2	88.1	89.8	81.7	78.2	83.8	91.4	96.6	90.5	87.0
+ Mr. Tydi	**94.0**	**98.6**	**92.2**	**92.7**	**94.5**	**88.8**	**88.9**	**92.4**	**93.7**	**98.9**	**95.2**	**93.6**

Для многоязычных экспериментов обучили mContriever на 29 языках.

Лучше всего справляются модели, файнтьюненные на MS MARCO (большой датасет для search и passage retrieval с разметкой правильных ответов)